

点估计

刘 赓

数学学院

2019年

§ 1. 矩估计法

矩估计法是英国统计学家K.皮尔逊 (K. Pearson) 在19世纪末到20世纪初的一系列文章中引进的。其基本思想就是利用样本矩来估计相应的总体矩，下面通过例子来说明。

§ 1. 矩估计法

矩估计法是英国统计学家K.皮尔逊 (K. Pearson) 在19世纪末到20世纪初的一系列文章中引进的。其基本思想就是利用样本矩来估计相应的总体矩, 下面通过例子来说明。

例1. 已知顾客在某银行的窗口等待服务的时间 X 服从 $Z(\alpha)$, 其中参数 α 未知。总体 X 的数学期望为 $E(X) = \frac{1}{\alpha}$ 。

§ 1. 矩估计法

矩估计法是英国统计学家K.皮尔逊 (K. Pearson) 在19世纪末到20世纪初的一系列文章中引进的。其基本思想就是利用样本矩来估计相应的总体矩, 下面通过例子来说明。

例1. 已知顾客在某银行的窗口等待服务的时间 X 服从 $Z(\alpha)$, 其中参数 α 未知。总体 X 的数学期望为 $E(X) = \frac{1}{\alpha}$ 。

设 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 其样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

§ 1. 矩估计法

矩估计法是英国统计学家K.皮尔逊 (K. Pearson) 在19世纪末到20世纪初的一系列文章中引进的。其基本思想就是利用样本矩来估计相应的总体矩, 下面通过例子来说明。

例1. 已知顾客在某银行的窗口等待服务的时间 X 服从 $Z(\alpha)$, 其中参数 α 未知。总体 X 的数学期望为 $E(X) = \frac{1}{\alpha}$ 。

设 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 其样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

一个很自然的想法就是, 随着样本容量 n 的逐渐增大, \bar{X} 也应该是越来越接近于总体均值 $\frac{1}{\alpha}$ 的。因此,

§ 1. 矩估计法

矩估计法是英国统计学家K.皮尔逊 (K. Pearson) 在19世纪末到20世纪初的一系列文章中引进的。其基本思想就是利用样本矩来估计相应的总体矩，下面通过例子来说明。

例1. 已知顾客在某银行的窗口等待服务的时间 X 服从 $Z(\alpha)$ ，其中参数 α 未知。总体 X 的数学期望为 $E(X) = \frac{1}{\alpha}$ 。

设 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本，其样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

一个很自然的想法就是，随着样本容量 n 的逐渐增大， \bar{X} 也应该是越来越接近于总体均值 $\frac{1}{\alpha}$ 的。因此，

$$E(X) = \frac{1}{\alpha} \hat{=} \bar{X}$$

§ 1. 矩估计法

矩估计法是英国统计学家K.皮尔逊 (K. Pearson) 在19世纪末到20世纪初的一系列文章中引进的。其基本思想就是利用样本矩来估计相应的总体矩，下面通过例子来说明。

例1. 已知顾客在某银行的窗口等待服务的时间 X 服从 $Z(\alpha)$ ，其中参数 α 未知。总体 X 的数学期望为 $E(X) = \frac{1}{\alpha}$ 。

设 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本，其样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

一个很自然的想法就是，随着样本容量 n 的逐渐增大， \bar{X} 也应该是越来越接近于总体均值 $\frac{1}{\alpha}$ 的。因此，

$$E(X) = \frac{1}{\alpha} \hat{=} \bar{X}$$

由此解得 α 的矩估计量 $\hat{\alpha} = \frac{1}{\bar{X}}$ 。

将以上过程的基本步骤总结如下：

将以上过程的基本步骤总结如下：

(1) 根据总体 X 的分布计算其数学期望，将 $E(X)$ 表示为待估参数 α 的函数 $g(\alpha) = \frac{1}{\alpha}$ ；

将以上过程的基本步骤总结如下：

(1) 根据总体 X 的分布计算其数学期望，将 $E(X)$ 表示为待估参数 α 的函数 $g(\alpha) = \frac{1}{\alpha}$ ；

(2) 利用对应的样本一阶原点矩 \bar{X} 估计 $E(X)$ （总体 X 的一阶原点矩）；

将以上过程的基本步骤总结如下：

(1) 根据总体 X 的分布计算其数学期望，将 $E(X)$ 表示为待估参数 α 的函数 $g(\alpha) = \frac{1}{\alpha}$ ；

(2) 利用对应的样本一阶原点矩 \bar{X} 估计 $E(X)$ （总体 X 的一阶原点矩）；

(3) 解方程 $g(\alpha) = \bar{X}$ ，将 α 用样本 X_1, X_2, \dots, X_n 表示出来，即为 α 的矩估计量。

将以上过程的基本步骤总结如下：

(1) 根据总体 X 的分布计算其数学期望，将 $E(X)$ 表示为待估参数 α 的函数 $g(\alpha) = \frac{1}{\alpha}$ ；

(2) 利用对应的样本一阶原点矩 \bar{X} 估计 $E(X)$ （总体 X 的一阶原点矩）；

(3) 解方程 $g(\alpha) = \bar{X}$ ，将 α 用样本 X_1, X_2, \dots, X_n 表示出来，即为 α 的矩估计量。

将以上思路推广至一般情况，如果待估参数有 k 个，则至少需要构造 k 个方程。

将以上过程的基本步骤总结如下：

(1) 根据总体 X 的分布计算其数学期望，将 $E(X)$ 表示为待估参数 α 的函数 $g(\alpha) = \frac{1}{\alpha}$ ；

(2) 利用对应的样本一阶原点矩 \bar{X} 估计 $E(X)$ （总体 X 的一阶原点矩）；

(3) 解方程 $g(\alpha) = \bar{X}$ ，将 α 用样本 X_1, X_2, \dots, X_n 表示出来，即为 α 的矩估计量。

将以上思路推广至一般情况，如果待估参数有 k 个，则至少需要构造 k 个方程。

例2. 设总体 X 服从 $N(\mu, \sigma^2)$ ，其中 μ 和 σ^2 是未知参数。试给出 μ 和 σ^2 的矩估计量。

将以上过程的基本步骤总结如下：

(1) 根据总体 X 的分布计算其数学期望，将 $E(X)$ 表示为待估参数 α 的函数 $g(\alpha) = \frac{1}{\alpha}$ ；

(2) 利用对应的样本一阶原点矩 \bar{X} 估计 $E(X)$ （总体 X 的一阶原点矩）；

(3) 解方程 $g(\alpha) = \bar{X}$ ，将 α 用样本 X_1, X_2, \dots, X_n 表示出来，即为 α 的矩估计量。

将以上思路推广至一般情况，如果待估参数有 k 个，则至少需要构造 k 个方程。

例2. 设总体 X 服从 $N(\mu, \sigma^2)$ ，其中 μ 和 σ^2 是未知参数。试给出 μ 和 σ^2 的矩估计量。

Def. 设总体 X 的分布函数为 $F(x; \theta_1, \dots, \theta_k)$ ，其中 $\theta_1, \dots, \theta_k$ 是未知参数。假定总体 X 的 r 阶原点矩 $E(X^r)$ ($1 \leq r \leq k$) 都存在，一般情况下 $E(X^r)$ 依赖于 $\theta_1, \dots, \theta_k$ ，记为

将以上过程的基本步骤总结如下：

(1) 根据总体 X 的分布计算其数学期望，将 $E(X)$ 表示为待估参数 α 的函数 $g(\alpha) = \frac{1}{\alpha}$ ；

(2) 利用对应的样本一阶原点矩 \bar{X} 估计 $E(X)$ （总体 X 的一阶原点矩）；

(3) 解方程 $g(\alpha) = \bar{X}$ ，将 α 用样本 X_1, X_2, \dots, X_n 表示出来，即为 α 的矩估计量。

将以上思路推广至一般情况，如果待估参数有 k 个，则至少需要构造 k 个方程。

例2. 设总体 X 服从 $N(\mu, \sigma^2)$ ，其中 μ 和 σ^2 是未知参数。试给出 μ 和 σ^2 的矩估计量。

Def. 设总体 X 的分布函数为 $F(x; \theta_1, \dots, \theta_k)$ ，其中 $\theta_1, \dots, \theta_k$ 是未知参数。假定总体 X 的 r 阶原点矩 $E(X^r)$ ($1 \leq r \leq k$) 都存在，一般情况下 $E(X^r)$ 依赖于 $\theta_1, \dots, \theta_k$ ，记为

$$E(X^r) = g_r(\theta_1, \dots, \theta_k), \quad r = 1, 2, \dots, k \quad (0.1)$$

将以上过程的基本步骤总结如下：

(1) 根据总体 X 的分布计算其数学期望，将 $E(X)$ 表示为待估参数 α 的函数 $g(\alpha) = \frac{1}{\alpha}$ ；

(2) 利用对应的样本一阶原点矩 \bar{X} 估计 $E(X)$ （总体 X 的一阶原点矩）；

(3) 解方程 $g(\alpha) = \bar{X}$ ，将 α 用样本 X_1, X_2, \dots, X_n 表示出来，即为 α 的矩估计量。

将以上思路推广至一般情况，如果待估参数有 k 个，则至少需要构造 k 个方程。

例2. 设总体 X 服从 $N(\mu, \sigma^2)$ ，其中 μ 和 σ^2 是未知参数。试给出 μ 和 σ^2 的矩估计量。

Def. 设总体 X 的分布函数为 $F(x; \theta_1, \dots, \theta_k)$ ，其中 $\theta_1, \dots, \theta_k$ 是未知参数。假定总体 X 的 r 阶原点矩 $E(X^r)$ ($1 \leq r \leq k$) 都存在，一般情况下 $E(X^r)$ 依赖于 $\theta_1, \dots, \theta_k$ ，记为

$$E(X^r) = g_r(\theta_1, \dots, \theta_k), \quad r = 1, 2, \dots, k \quad (0.1)$$

样本 r 阶原点矩

$$\overline{X^r} = \frac{1}{n} \sum_{i=1}^n X_i^r, \quad r = 1, 2, \dots, k \quad (0.2)$$

样本 r 阶原点矩

$$\overline{X^r} = \frac{1}{n} \sum_{i=1}^n X_i^r, \quad r = 1, 2, \dots, k \quad (0.2)$$

令样本 r 阶原点矩等于总体 X 的 r 阶原点矩 ($r = 1, 2, \dots, k$) , 即

样本 r 阶原点矩

$$\overline{X^r} = \frac{1}{n} \sum_{i=1}^n X_i^r, \quad r = 1, 2, \dots, k \quad (0.2)$$

令样本 r 阶原点矩等于总体 X 的 r 阶原点矩 ($r = 1, 2, \dots, k$) , 即

$$\begin{cases} E(X) = g_1(\theta_1, \dots, \theta_k) & \hat{=} \frac{1}{n} \sum_{i=1}^n X_i = \overline{X} \\ E(X^2) = g_2(\theta_1, \dots, \theta_k) & \hat{=} \frac{1}{n} \sum_{i=1}^n X_i^2 = \overline{X^2} \\ \vdots & \\ E(X^k) = g_k(\theta_1, \dots, \theta_k) & \hat{=} \frac{1}{n} \sum_{i=1}^n X_i^k = \overline{X^k} \end{cases} \quad (0.3)$$

样本 r 阶原点矩

$$\overline{X^r} = \frac{1}{n} \sum_{i=1}^n X_i^r, \quad r = 1, 2, \dots, k \quad (0.2)$$

令样本 r 阶原点矩等于总体 X 的 r 阶原点矩 ($r = 1, 2, \dots, k$) , 即

$$\begin{cases} E(X) = g_1(\theta_1, \dots, \theta_k) & \hat{=} \frac{1}{n} \sum_{i=1}^n X_i = \overline{X} \\ E(X^2) = g_2(\theta_1, \dots, \theta_k) & \hat{=} \frac{1}{n} \sum_{i=1}^n X_i^2 = \overline{X^2} \\ \vdots & \\ E(X^k) = g_k(\theta_1, \dots, \theta_k) & \hat{=} \frac{1}{n} \sum_{i=1}^n X_i^k = \overline{X^k} \end{cases} \quad (0.3)$$

求解该方程组, 即可得到参数 $\theta_1, \dots, \theta_k$ 的矩估计量

$$\hat{\theta}_r = \hat{\theta}_r(X_1, X_2, \dots, X_n), \quad r = 1, 2, \dots, k$$

注意:

注意:

(1) 定义中选用的是原点矩, 也可以用中心矩。只要给定总体矩, 采用相应的样本矩估计即可。

注意:

(1) 定义中选用的是原点矩, 也可以用中心矩。只要给定总体矩, 采用相应的样本矩估计即可。

(2) 如果要估计的是函数 $h(\theta_1, \dots, \theta_k)$, 则用 $\hat{h} = h(\hat{\theta}_1, \dots, \hat{\theta}_k)$ 来估计它, 称之为矩法估计量。

注意:

(1) 定义中选用的是原点矩, 也可以用中心矩。只要给定总体矩, 采用相应的样本矩估计即可。

(2) 如果要估计的是函数 $h(\theta_1, \dots, \theta_k)$, 则用 $\hat{h} = h(\hat{\theta}_1, \dots, \hat{\theta}_k)$ 来估计它, 称之为矩法估计量。

(3) 使用矩估计法的前提就是所需要的总体矩必须存在。

注意:

(1) 定义中选用的是原点矩, 也可以用中心矩。只要给定总体矩, 采用相应的样本矩估计即可。

(2) 如果要估计的是函数 $h(\theta_1, \dots, \theta_k)$, 则用 $\hat{h} = h(\hat{\theta}_1, \dots, \hat{\theta}_k)$ 来估计它, 称之为矩法估计量。

(3) 使用矩估计法的前提就是所需要的总体矩必须存在。

例3. 设总体 X 服从 $\pi(\lambda)$, 其中 $\lambda > 0$ 是未知参数。试求参数 λ 的矩估计量。

注意:

(1) 定义中选用的是原点矩, 也可以用中心矩。只要给定总体矩, 采用相应的样本矩估计即可。

(2) 如果要估计的是函数 $h(\theta_1, \dots, \theta_k)$, 则用 $\hat{h} = h(\hat{\theta}_1, \dots, \hat{\theta}_k)$ 来估计它, 称之为矩法估计量。

(3) 使用矩估计法的前提就是所需要的总体矩必须存在。

例3. 设总体 X 服从 $\pi(\lambda)$, 其中 $\lambda > 0$ 是未知参数。试求参数 λ 的矩估计量。

例4 设总体 X 的概率密度为

$$f(x; \theta) = \frac{1}{2\theta} e^{\frac{-|x|}{\theta}}, \quad -\infty < x < +\infty, \theta > 0$$

试求参数 θ 的矩估计量。

§ 2. 最大似然估计法

最大似然估计 (*Maximum Likelihood Estimation*, 简记为MLE) 的思想始于高斯的误差理论, 由费歇尔 (R. A. Fisher) 于20世纪20年代将其作为一个一般的估计方法提出来。

§ 2. 最大似然估计法

最大似然估计 (*Maximum Likelihood Estimation*, 简记为MLE) 的思想始于高斯的误差理论, 由费歇尔 (R. A. Fisher) 于20世纪20年代将其作为一个一般的估计方法提出来。

一. 似然函数 (*Likelihood function*)

§ 2. 最大似然估计法

最大似然估计 (*Maximum Likelihood Estimation*, 简记为MLE) 的思想始于高斯的误差理论, 由费歇尔 (R. A. Fisher) 于20世纪20年代将其作为一个一般的估计方法提出来。

一. 似然函数 (*Likelihood function*)

1. 离散型总体

§ 2. 最大似然估计法

最大似然估计 (*Maximum Likelihood Estimation*, 简记为MLE) 的思想始于高斯的误差理论, 由费歇尔 (R. A. Fisher) 于20世纪20年代将其作为一个一般的估计方法提出来。

一. 似然函数 (*Likelihood function*)

1. 离散型总体

$$L(\theta_1, \dots, \theta_k) = \prod_{i=1}^n p(x_i; \theta_1, \dots, \theta_k) \quad (0.4)$$

§ 2. 最大似然估计法

最大似然估计 (*Maximum Likelihood Estimation*, 简记为MLE) 的思想始于高斯的误差理论, 由费歇尔 (R. A. Fisher) 于20世纪20年代将其作为一个一般的估计方法提出来。

一. 似然函数 (*Likelihood function*)

1. 离散型总体

$$L(\theta_1, \dots, \theta_k) = \prod_{i=1}^n p(x_i; \theta_1, \dots, \theta_k) \quad (0.4)$$

2. 连续型总体

§ 2. 最大似然估计法

最大似然估计 (*Maximum Likelihood Estimation*, 简记为MLE) 的思想始于高斯的误差理论, 由费歇尔 (R. A. Fisher) 于20世纪20年代将其作为一个一般的估计方法提出来。

一. 似然函数 (*Likelihood function*)

1. 离散型总体

$$L(\theta_1, \dots, \theta_k) = \prod_{i=1}^n p(x_i; \theta_1, \dots, \theta_k) \quad (0.4)$$

2. 连续型总体

$$L(\theta_1, \dots, \theta_k) = \prod_{i=1}^n f(x_i; \theta_1, \dots, \theta_k) \quad (0.5)$$

二. 最大似然估计

二. 最大似然估计

Def. 似然函数 $L(x_1, x_2, \dots, x_n; \theta)$, x_1, x_2, \dots, x_n 是样本观测值, $\theta = (\theta_1, \dots, \theta_k)$ 为未知参数, Θ 是参数空间。若存在 $(\hat{\theta}_1, \dots, \hat{\theta}_k) \in \Theta$, 使得

二. 最大似然估计

Def. 似然函数 $L(x_1, x_2, \dots, x_n; \theta)$, x_1, x_2, \dots, x_n 是样本观测值, $\theta = (\theta_1, \dots, \theta_k)$ 为未知参数, Θ 是参数空间。若存在 $(\hat{\theta}_1, \dots, \hat{\theta}_k) \in \Theta$, 使得

$$L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \dots, \hat{\theta}_k) = \max_{\theta_1, \dots, \theta_k} L(x_1, x_2, \dots, x_n; \theta_1, \dots, \theta_k)$$

二. 最大似然估计

Def. 似然函数 $L(x_1, x_2, \dots, x_n; \theta)$, x_1, x_2, \dots, x_n 是样本观测值, $\theta = (\theta_1, \dots, \theta_k)$ 为未知参数, Θ 是参数空间。若存在 $(\hat{\theta}_1, \dots, \hat{\theta}_k) \in \Theta$, 使得

$$L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \dots, \hat{\theta}_k) = \max_{\theta_1, \dots, \theta_k} L(x_1, x_2, \dots, x_n; \theta_1, \dots, \theta_k)$$

则称 $\hat{\theta}_r = \hat{\theta}_r(x_1, x_2, \dots, x_n)$ ($r = 1, 2, \dots, k$) 为参数 $\theta_1, \dots, \theta_k$ 的最大似然估计值, 称 $\hat{\theta}_r = \hat{\theta}_r(X_1, X_2, \dots, X_n)$ 为最大似然估计量。

二. 最大似然估计

Def. 似然函数 $L(x_1, x_2, \dots, x_n; \theta)$, x_1, x_2, \dots, x_n 是样本观测值, $\theta = (\theta_1, \dots, \theta_k)$ 为未知参数, Θ 是参数空间。若存在 $(\hat{\theta}_1, \dots, \hat{\theta}_k) \in \Theta$, 使得

$$L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \dots, \hat{\theta}_k) = \max_{\theta_1, \dots, \theta_k} L(x_1, x_2, \dots, x_n; \theta_1, \dots, \theta_k)$$

则称 $\hat{\theta}_r = \hat{\theta}_r(x_1, x_2, \dots, x_n)$ ($r = 1, 2, \dots, k$) 为参数 $\theta_1, \dots, \theta_k$ 的最大似然估计值, 称 $\hat{\theta}_r = \hat{\theta}_r(X_1, X_2, \dots, X_n)$ 为最大似然估计量。

三. 似然方程/ 对数似然方程

二. 最大似然估计

Def. 似然函数 $L(x_1, x_2, \dots, x_n; \theta)$, x_1, x_2, \dots, x_n 是样本观测值, $\theta = (\theta_1, \dots, \theta_k)$ 为未知参数, Θ 是参数空间。若存在 $(\hat{\theta}_1, \dots, \hat{\theta}_k) \in \Theta$, 使得

$$L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \dots, \hat{\theta}_k) = \max_{\theta_1, \dots, \theta_k} L(x_1, x_2, \dots, x_n; \theta_1, \dots, \theta_k)$$

则称 $\hat{\theta}_r = \hat{\theta}_r(x_1, x_2, \dots, x_n)$ ($r = 1, 2, \dots, k$) 为参数 $\theta_1, \dots, \theta_k$ 的最大似然估计值, 称 $\hat{\theta}_r = \hat{\theta}_r(X_1, X_2, \dots, X_n)$ 为最大似然估计量。

三. 似然方程/ 对数似然方程

$$\frac{\partial L(\theta)}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k \quad (0.6)$$

二. 最大似然估计

Def. 似然函数 $L(x_1, x_2, \dots, x_n; \theta)$, x_1, x_2, \dots, x_n 是样本观测值, $\theta = (\theta_1, \dots, \theta_k)$ 为未知参数, Θ 是参数空间。若存在 $(\hat{\theta}_1, \dots, \hat{\theta}_k) \in \Theta$, 使得

$$L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \dots, \hat{\theta}_k) = \max_{\theta_1, \dots, \theta_k} L(x_1, x_2, \dots, x_n; \theta_1, \dots, \theta_k)$$

则称 $\hat{\theta}_r = \hat{\theta}_r(x_1, x_2, \dots, x_n)$ ($r = 1, 2, \dots, k$) 为参数 $\theta_1, \dots, \theta_k$ 的最大似然估计值, 称 $\hat{\theta}_r = \hat{\theta}_r(X_1, X_2, \dots, X_n)$ 为最大似然估计量。

三. 似然方程/ 对数似然方程

$$\frac{\partial L(\theta)}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k \quad (0.6)$$

$$\frac{\partial \ln L(\theta)}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k \quad (0.7)$$

最大似然估计法的基本步骤如下：

最大似然估计法的基本步骤如下:

(1) 根据总体 X 的分布, 建立似然函数 $L(\theta_1, \dots, \theta_k)$:

最大似然估计法的基本步骤如下:

- (1) 根据总体 X 的分布, 建立似然函数 $L(\theta_1, \dots, \theta_k)$;
- (2) 给出对数似然函数 $\ln L(\theta_1, \dots, \theta_k)$;

最大似然估计法的基本步骤如下:

- (1) 根据总体 X 的分布, 建立似然函数 $L(\theta_1, \dots, \theta_k)$;
- (2) 给出对数似然函数 $\ln L(\theta_1, \dots, \theta_k)$;
- (3) 建立似然方程组:

$$\frac{\partial L(\theta)}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k$$

最大似然估计法的基本步骤如下:

- (1) 根据总体 X 的分布, 建立似然函数 $L(\theta_1, \dots, \theta_k)$;
- (2) 给出对数似然函数 $\ln L(\theta_1, \dots, \theta_k)$;
- (3) 建立似然方程组:

$$\frac{\partial L(\theta)}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k$$

或对数似然方程组:

$$\frac{\partial \ln L(\theta)}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k$$

最大似然估计法的基本步骤如下:

- (1) 根据总体 X 的分布, 建立似然函数 $L(\theta_1, \dots, \theta_k)$;
- (2) 给出对数似然函数 $\ln L(\theta_1, \dots, \theta_k)$;
- (3) 建立似然方程组:

$$\frac{\partial L(\theta)}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k$$

或对数似然方程组:

$$\frac{\partial \ln L(\theta)}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k$$

- (4) 根据似然方程组或对数似然方程组求解最大似然估计量。

例1. 设总体 X 服从 $Z(\alpha)$, 其中 $\alpha > 0$ 是未知参数。 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 试求参数 α 的最大似然估计量。

例1. 设总体 X 服从 $Z(\alpha)$, 其中 $\alpha > 0$ 是未知参数。 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 试求参数 α 的最大似然估计量。

解: 已知 $X \sim Z(\alpha)$, 其密度函数为

$$f(x; \alpha) = \begin{cases} \alpha e^{-\alpha x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

例1. 设总体 X 服从 $Z(\alpha)$, 其中 $\alpha > 0$ 是未知参数。 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 试求参数 α 的最大似然估计量。

解: 已知 $X \sim Z(\alpha)$, 其密度函数为

$$f(x; \alpha) = \begin{cases} \alpha e^{-\alpha x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

(1) 建立似然函数:

例1. 设总体 X 服从 $Z(\alpha)$, 其中 $\alpha > 0$ 是未知参数。 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 试求参数 α 的最大似然估计量。

解: 已知 $X \sim Z(\alpha)$, 其密度函数为

$$f(x; \alpha) = \begin{cases} \alpha e^{-\alpha x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

(1) 建立似然函数:

$$\begin{aligned} L(\alpha) &= L(x_1, x_2, \dots, x_n; \alpha) \\ &= \prod_{i=1}^n \alpha e^{-\alpha x_i} \\ &= \alpha^n e^{-\alpha \sum_{i=1}^n x_i}, \quad \forall x_i > 0 \end{aligned}$$

例1. 设总体 X 服从 $Z(\alpha)$, 其中 $\alpha > 0$ 是未知参数。 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 试求参数 α 的最大似然估计量。

解: 已知 $X \sim Z(\alpha)$, 其密度函数为

$$f(x; \alpha) = \begin{cases} \alpha e^{-\alpha x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

(1) 建立似然函数:

$$\begin{aligned} L(\alpha) &= L(x_1, x_2, \dots, x_n; \alpha) \\ &= \prod_{i=1}^n \alpha e^{-\alpha x_i} \\ &= \alpha^n e^{-\alpha \sum_{i=1}^n x_i}, \quad \forall x_i > 0 \end{aligned}$$

(2) 取对数, 得到对数似然函数:

例1. 设总体 X 服从 $Z(\alpha)$, 其中 $\alpha > 0$ 是未知参数。 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 试求参数 α 的最大似然估计量。

解: 已知 $X \sim Z(\alpha)$, 其密度函数为

$$f(x; \alpha) = \begin{cases} \alpha e^{-\alpha x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

(1) 建立似然函数:

$$\begin{aligned} L(\alpha) &= L(x_1, x_2, \dots, x_n; \alpha) \\ &= \prod_{i=1}^n \alpha e^{-\alpha x_i} \\ &= \alpha^n e^{-\alpha \sum_{i=1}^n x_i}, \quad \forall x_i > 0 \end{aligned}$$

(2) 取对数, 得到对数似然函数:

$$\ln L(\alpha) = n \ln \alpha - \alpha \sum_{i=1}^n x_i$$

(3) 两边对 α 求导，建立对数似然方程：

(3) 两边对 α 求导，建立对数似然方程：

$$\frac{d \ln L(\alpha)}{d\alpha} = \frac{n}{\alpha} - \sum_{i=1}^n x_i = 0$$

(3) 两边对 α 求导，建立对数似然方程：

$$\frac{d \ln L(\alpha)}{d\alpha} = \frac{n}{\alpha} - \sum_{i=1}^n x_i = 0$$

(4) 求解对数似然方程，得到 α 的最大似然估计值为

(3) 两边对 α 求导，建立对数似然方程：

$$\frac{d \ln L(\alpha)}{d\alpha} = \frac{n}{\alpha} - \sum_{i=1}^n x_i = 0$$

(4) 求解对数似然方程，得到 α 的最大似然估计值为

$$\hat{\alpha} = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{x}}$$

(3) 两边对 α 求导，建立对数似然方程：

$$\frac{d \ln L(\alpha)}{d\alpha} = \frac{n}{\alpha} - \sum_{i=1}^n x_i = 0$$

(4) 求解对数似然方程，得到 α 的最大似然估计值为

$$\hat{\alpha} = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{x}}$$

故其最大似然估计量为 $\hat{\alpha} = \frac{1}{\bar{X}}$

(3) 两边对 α 求导, 建立对数似然方程:

$$\frac{d \ln L(\alpha)}{d\alpha} = \frac{n}{\alpha} - \sum_{i=1}^n x_i = 0$$

(4) 求解对数似然方程, 得到 α 的最大似然估计值为

$$\hat{\alpha} = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{x}}$$

故其最大似然估计量为 $\hat{\alpha} = \frac{1}{\bar{X}}$

例2. 设总体 X 服从 $\pi(\lambda)$, 其中 $\lambda > 0$ 是未知参数。 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 试求参数 λ 的最大似然估计量。

例3. 设总体 X 服从正态分布 $N(\mu, \sigma^2)$, 其中 μ 和 σ^2 是未知参数。
已知 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 试给出 μ 和 σ^2 的最大似然估计量。

例3. 设总体 X 服从正态分布 $N(\mu, \sigma^2)$, 其中 μ 和 σ^2 是未知参数。已知 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 试给出 μ 和 σ^2 的最大似然估计量。

例4. (接上例) 若 μ 是已知的, 而 σ^2 是未知参数。试给出 σ^2 的最大似然估计量。

例3. 设总体 X 服从正态分布 $N(\mu, \sigma^2)$, 其中 μ 和 σ^2 是未知参数。已知 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 试给出 μ 和 σ^2 的最大似然估计量。

例4. (接上例) 若 μ 是已知的, 而 σ^2 是未知参数。试给出 σ^2 的最大似然估计量。

例5. 设总体 X 在 $[a, b]$ 上服从均匀分布, a 、 b 未知。试给出 a 和 b 的最大似然估计量。

例3. 设总体 X 服从正态分布 $N(\mu, \sigma^2)$, 其中 μ 和 σ^2 是未知参数。已知 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 试给出 μ 和 σ^2 的最大似然估计量。

例4. (接上例) 若 μ 是已知的, 而 σ^2 是未知参数。试给出 σ^2 的最大似然估计量。

例5. 设总体 X 在 $[a, b]$ 上服从均匀分布, a 、 b 未知。试给出 a 和 b 的最大似然估计量。

例6. 设总体 X 的密度函数为

$$f(x; \mu, \lambda) = \begin{cases} \lambda e^{-\lambda(x-\mu)}, & x \geq \mu \\ 0 & x < \mu \end{cases}$$

参数 $\lambda > 0$ 。已知 X_1, X_2, \dots, X_n 是来自该总体的一个简单随机样本, 求参数 λ 和 μ 的最大似然估计量。

注意以下几点:

注意以下几点:

(1) 似然函数的给出是使用最大似然估计法的基本前提, 因此要求总体 X 的分布律或密度函数的表达式是已知的;

注意以下几点:

(1) 似然函数的给出是使用最大似然估计法的基本前提, 因此要求总体 X 的分布律或密度函数的表达式是已知的;

(2) 多数情况下, 可以通过求导或求偏导, 建立方程或方程组来求解最大似然估计量;

注意以下几点:

(1) 似然函数的给出是使用最大似然估计法的基本前提, 因此要求总体 X 的分布律或密度函数的表达式是已知的;

(2) 多数情况下, 可以通过求导或求偏导, 建立方程或方程组来求解最大似然估计量;

(3) 当待估参数是函数的分段点时, 通常可以利用顺序统计量确定最大似然估计量。

注意以下几点:

(1) 似然函数的给出是使用最大似然估计法的基本前提, 因此要求总体 X 的分布律或密度函数的表达式是已知的;

(2) 多数情况下, 可以通过求导或求偏导, 建立方程或方程组来求解最大似然估计量;

(3) 当待估参数是函数的分段点时, 通常可以利用顺序统计量确定最大似然估计量。

命题. θ 是总体 X 的分布的未知参数, $u = u(\theta)$ ($\theta \in \Theta$) 是 θ 的函数, 具有单值反函数 $\theta = \theta(u)$, 且设 $\hat{\theta}$ 是 θ 的最大似然估计, 则 $\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的最大似然估计。

注意以下几点:

(1) 似然函数的给出是使用最大似然估计法的基本前提, 因此要求总体 X 的分布律或密度函数的表达式是已知的;

(2) 多数情况下, 可以通过求导或求偏导, 建立方程或方程组来求解最大似然估计量;

(3) 当待估参数是函数的分段点时, 通常可以利用顺序统计量确定最大似然估计量。

命题. θ 是总体 X 的分布的未知参数, $u = u(\theta)$ ($\theta \in \Theta$) 是 θ 的函数, 具有单值反函数 $\theta = \theta(u)$, 且设 $\hat{\theta}$ 是 θ 的最大似然估计, 则 $\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的最大似然估计。

上述性质也称为最大似然估计的不变性, 在一定情况下可以用来估计参数的函数。

§ 3. 估计量的评选标准

§ 3. 估计量的评选标准

$$\begin{aligned}MSE(\hat{\theta}) &= E\left[(\hat{\theta} - \theta)^2\right] \\&= E\left[\left((\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)\right)^2\right] \\&= E\left[(\hat{\theta} - E(\hat{\theta}))^2\right] + (E(\hat{\theta}) - \theta)^2 \\&= D(\hat{\theta}) + (E(\hat{\theta}) - \theta)^2\end{aligned}$$

§ 3. 估计量的评选标准

$$\begin{aligned}MSE(\hat{\theta}) &= E\left[(\hat{\theta} - \theta)^2\right] \\&= E\left[\left((\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)\right)^2\right] \\&= E\left[(\hat{\theta} - E(\hat{\theta}))^2\right] + (E(\hat{\theta}) - \theta)^2 \\&= D(\hat{\theta}) + (E(\hat{\theta}) - \theta)^2\end{aligned}$$

一. 无偏性 (unbiasedness)

§ 3. 估计量的评选标准

$$\begin{aligned}MSE(\hat{\theta}) &= E\left[(\hat{\theta} - \theta)^2\right] \\&= E\left[\left((\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)\right)^2\right] \\&= E\left[(\hat{\theta} - E(\hat{\theta}))^2\right] + (E(\hat{\theta}) - \theta)^2 \\&= D(\hat{\theta}) + (E(\hat{\theta}) - \theta)^2\end{aligned}$$

一. 无偏性 (unbiasedness)

Def. 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的一个估计量, 若

§ 3. 估计量的评选标准

$$\begin{aligned}MSE(\hat{\theta}) &= E\left[(\hat{\theta} - \theta)^2\right] \\&= E\left[\left((\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)\right)^2\right] \\&= E\left[(\hat{\theta} - E(\hat{\theta}))^2\right] + (E(\hat{\theta}) - \theta)^2 \\&= D(\hat{\theta}) + (E(\hat{\theta}) - \theta)^2\end{aligned}$$

一. 无偏性 (unbiasedness)

Def. 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的一个估计量, 若

$$E(\hat{\theta}) = \theta \quad (0.8)$$

§ 3. 估计量的评选标准

$$\begin{aligned}MSE(\hat{\theta}) &= E\left[(\hat{\theta} - \theta)^2\right] \\&= E\left[\left((\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)\right)^2\right] \\&= E\left[(\hat{\theta} - E(\hat{\theta}))^2\right] + (E(\hat{\theta}) - \theta)^2 \\&= D(\hat{\theta}) + (E(\hat{\theta}) - \theta)^2\end{aligned}$$

一. 无偏性 (unbiasedness)

Def. 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的一个估计量, 若

$$E(\hat{\theta}) = \theta \quad (0.8)$$

则称 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的无偏估计量。如果 $\hat{\theta}$ 不是无偏的,

其差

$$b_n = E(\hat{\theta}) - \theta \quad (0.9)$$

称为 $\hat{\theta}$ 的偏差。

其差

$$b_n = E(\hat{\theta}) - \theta \quad (0.9)$$

称为 $\hat{\theta}$ 的偏差。

特别，若 $\lim_{n \rightarrow \infty} b_n = 0$ ，则称 $\hat{\theta}$ 是 θ 的渐近无偏估计量。

其差

$$b_n = E(\hat{\theta}) - \theta \quad (0.9)$$

称为 $\hat{\theta}$ 的偏差。

特别，若 $\lim_{n \rightarrow \infty} b_n = 0$ ，则称 $\hat{\theta}$ 是 θ 的渐近无偏估计量。

例1. 设 X_1, X_2, \dots, X_n 是来自总体 X 的样本，若 $D(X) = \sigma^2$ 是有限的。试证：样本二阶中心矩 S_n^2 是 σ^2 的有偏估计量。

其差

$$b_n = E(\hat{\theta}) - \theta \quad (0.9)$$

称为 $\hat{\theta}$ 的偏差。

特别, 若 $\lim_{n \rightarrow \infty} b_n = 0$, 则称 $\hat{\theta}$ 是 θ 的渐近无偏估计量。

例1. 设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, 若 $D(X) = \sigma^2$ 是有限的。试证: 样本二阶中心矩 S_n^2 是 σ^2 的有偏估计量。

命题. 设 X_1, X_2, \dots, X_n 是来自总体 X 的简单随机样本。无论总体 X 服从什么分布, 只要其数学期望 μ 和方差 σ^2 存在且有限, 则

其差

$$b_n = E(\hat{\theta}) - \theta \quad (0.9)$$

称为 $\hat{\theta}$ 的偏差。

特别, 若 $\lim_{n \rightarrow \infty} b_n = 0$, 则称 $\hat{\theta}$ 是 θ 的渐近无偏估计量。

例1. 设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, 若 $D(X) = \sigma^2$ 是有限的。试证: 样本二阶中心矩 S_n^2 是 σ^2 的有偏估计量。

命题. 设 X_1, X_2, \dots, X_n 是来自总体 X 的简单随机样本。无论总体 X 服从什么分布, 只要其数学期望 μ 和方差 σ^2 存在且有限, 则

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

分别是 μ 和 σ^2 的无偏估计量。

其差

$$b_n = E(\hat{\theta}) - \theta \quad (0.9)$$

称为 $\hat{\theta}$ 的偏差。

特别, 若 $\lim_{n \rightarrow \infty} b_n = 0$, 则称 $\hat{\theta}$ 是 θ 的渐近无偏估计量。

例1. 设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, 若 $D(X) = \sigma^2$ 是有限的。试证: 样本二阶中心矩 S_n^2 是 σ^2 的有偏估计量。

命题. 设 X_1, X_2, \dots, X_n 是来自总体 X 的简单随机样本。无论总体 X 服从什么分布, 只要其数学期望 μ 和方差 σ^2 存在且有限, 则

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

分别是 μ 和 σ^2 的无偏估计量。

注意: 当 $\hat{\theta}$ 是 θ 的无偏估计量时, $g(\hat{\theta})$ 并不一定是 $g(\theta)$ 的无偏估计量。

例2. 设总体 X 服从指数分布 $Exp\left(\frac{1}{\theta}\right)$, 其密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

其中 θ 是未知参数。 X_1, X_2, \dots, X_n 是简单随机样本, $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ 是相应的顺序统计量。

试证明 \bar{X} 和 $nX_{(1)}$ 都是 θ 的无偏估计量。

例2. 设总体 X 服从指数分布 $Exp\left(\frac{1}{\theta}\right)$, 其密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

其中 θ 是未知参数。 X_1, X_2, \dots, X_n 是简单随机样本, $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ 是相应的顺序统计量。

试证明 \bar{X} 和 $nX_{(1)}$ 都是 θ 的无偏估计量。

二. 有效性 (efficiency)

例2. 设总体 X 服从指数分布 $Exp\left(\frac{1}{\theta}\right)$, 其密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

其中 θ 是未知参数。 X_1, X_2, \dots, X_n 是简单随机样本, $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ 是相应的顺序统计量。

试证明 \bar{X} 和 $nX_{(1)}$ 都是 θ 的无偏估计量。

二. 有效性 (efficiency)

Def. 设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, \dots, X_n)$ 都是未知参数 θ 的无偏估计量, 若

$$D(\hat{\theta}_1) < D(\hat{\theta}_2) \quad (0.10)$$

则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

例3. 设总体 X 在 $[0, \theta]$ 上服从均匀分布, $\theta > 0$ 是未知参数。

例3. 设总体 X 在 $[0, \theta]$ 上服从均匀分布, $\theta > 0$ 是未知参数。

证明 $\hat{\theta}_1 = 2\bar{X}$ 和 $\hat{\theta}_2 = \frac{n+1}{n}X_{(n)}$ 都是 θ 的无偏估计量。并说明 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 哪一个更有效?

例3. 设总体 X 在 $[0, \theta]$ 上服从均匀分布, $\theta > 0$ 是未知参数。

证明 $\hat{\theta}_1 = 2\bar{X}$ 和 $\hat{\theta}_2 = \frac{n+1}{n}X_{(n)}$ 都是 θ 的无偏估计量。并说明 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 哪一个更有效?

三. 相合性 (consistency)

例3. 设总体 X 在 $[0, \theta]$ 上服从均匀分布, $\theta > 0$ 是未知参数。

证明 $\hat{\theta}_1 = 2\bar{X}$ 和 $\hat{\theta}_2 = \frac{n+1}{n}X_{(n)}$ 都是 θ 的无偏估计量。并说明 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 哪一个更有效?

三. 相合性 (consistency)

Def. 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的估计量, 若对于任意的 $\theta \in \Theta$, 当 $n \rightarrow \infty$ 时, $\hat{\theta}$ 依概率收敛于 θ , 则称 $\hat{\theta}$ 是 θ 的相合估计量, 或一致估计量。即 $\forall \varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P \{ |\hat{\theta} - \theta| < \varepsilon \} = 1 \quad (0.11)$$

记为 $\hat{\theta} \xrightarrow{P} \theta$ 。

例3. 设总体 X 在 $[0, \theta]$ 上服从均匀分布, $\theta > 0$ 是未知参数。

证明 $\hat{\theta}_1 = 2\bar{X}$ 和 $\hat{\theta}_2 = \frac{n+1}{n}X_{(n)}$ 都是 θ 的无偏估计量。并说明 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 哪一个更有效?

三. 相合性 (consistency)

Def. 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的估计量, 若对于任意的 $\theta \in \Theta$, 当 $n \rightarrow \infty$ 时, $\hat{\theta}$ 依概率收敛于 θ , 则称 $\hat{\theta}$ 是 θ 的相合估计量, 或一致估计量。即 $\forall \varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| < \varepsilon\} = 1 \quad (0.11)$$

记为 $\hat{\theta} \xrightarrow{P} \theta$ 。

相合性是评价估计量优劣的一个重要标准, 也是对估计量的一个基本要求。如果一个估计量不具有相合性, 那么随着样本容量 n 的增大, 对未知参数估计的精度并不一定能提高, 估计量甚至会明显偏离被估参数。